

UNIVERSIDADE FEDERAL DO RIO GRANDE DO SUL
ESCOLA DE ENGENHARIA
DEPARTAMENTO DE ENGENHARIA ELÉTRICA
GRADUAÇÃO EM ENGENHARIA ELÉTRICA

VICENTE COSTAMILAN DA CUNHA

**Métodos de Segmentação Automática de Sinais
de Eletromiografia para Classificação de
Movimentos Utilizando Redes Neurais
Artificiais**

Porto Alegre

2015

UNIVERSIDADE FEDERAL DO RIO GRANDE DO SUL
ESCOLA DE ENGENHARIA
DEPARTAMENTO DE ENGENHARIA ELÉTRICA
GRADUAÇÃO EM ENGENHARIA ELÉTRICA

VICENTE COSTAMILAN DA CUNHA

**Métodos de Segmentação Automática de Sinais de
Eletromiografia para Classificação de Movimentos
Utilizando Redes Neurais Artificiais**

Projeto de Diplomação apresentado ao Departamento de Engenharia Elétrica da Escola de Engenharia da Universidade Federal do Rio Grande do Sul, como requisito parcial para Graduação em Engenharia Elétrica

Orientador: Prof. Dr. Eng. Alexandre Balbinot

Porto Alegre

2015

INSERIR A FICHA BIBLIOGRÁFICA

UNIVERSIDADE FEDERAL DO RIO GRANDE DO SUL
ESCOLA DE ENGENHARIA
DEPARTAMENTO DE ENGENHARIA ELÉTRICA
GRADUAÇÃO EM ENGENHARIA ELÉTRICA

VICENTE COSTAMILAN DA CUNHA

**Métodos de Segmentação Automática de Sinais de
Eletromiografia para Classificação de Movimentos
Utilizando Redes Neurais Artificiais**

Projeto de Diplomação apresentado ao Departamento de Engenharia Elétrica da Escola de Engenharia da Universidade Federal do Rio Grande do Sul, como requisito parcial para Graduação em Engenharia Elétrica

Trabalho aprovado. Porto Alegre, XX de XXXXXX de 2015:

Prof. Dr. Eng. Alexandre Balbinot
Orientador

Professor
Convidado 1

Professor
Convidado 2

Porto Alegre
2015

INSERIR DEDICATÓRIA

Agradecimentos

INSERIR AGRADECIMENTOS

INSERIR EPÍGRAFE

Resumo

A segmentação de sinais de eletromiografia (EMG) é parte essencial de pré-processamento em aplicações de reconhecimento de movimentos e controle de próteses, separando trechos de interesse do sinal correspondentes a esforços musculares e descartando trechos de sinal com baixa atividade muscular. Neste estudo, quatro métodos para segmentação automática de sinais de EMG foram implementados em MATLAB. Os métodos foram aplicados aos sinais da base de dados realizada por (LOPES, 2014) e a base de dados Ninapro (ATZORI et al, 2012). Uma rede neural artificial foi utilizada para classificar os movimentos realizados correspondentes aos sinais segmentados com os quatro métodos. Os resultados para classificação utilizando os diferentes métodos mostram que [resultados aqui].

Palavras-chave: Eletromiografia. Segmentação. MATLAB. Base de dados Ninapro.

Abstract

TRADUZIR RESUMO

Keywords: Eletromiography. Segmentation. MATLAB. Ninapro database.

Lista de ilustrações

Figura 1 – Soma de potenciais de ação das n fibras de uma unidade motora, formando uma MUAP $h(t)$. Adaptado de BASMAJIAN e DE LUCA, 1985	16
Figura 2 – Os sinais de MUAP correspondentes a três diferentes unidades motoras somam-se para formar o sinal adquirido por um canal de EMG. Adaptado de HAMMARBERG and STERNAD, 2002	17
Figura 3 – MUAPTs de diferentes MUs somam-se para compor o sinal adquirido por um canal de EMG. Adaptado de KLINE and DE LUCA, 2014 . . .	17
Figura 4 – Ilustração da implementação do MTD1, com $q = 0.9$ e $l = 401$. Do autor.	20
Figura 5 – Ilustração da implementação do MTD2, com $l = 401$. Do autor.	21
Figura 6 – Ilustração da implementação do MTD3, com $W = 100$. Do autor.	22
Figura 7 – Ilustração da implementação do MTD4, com $W = 100$ e $T = 0,5$. Do autor.	23

Lista de tabelas

Tabela 1 – Parâmetros utilizados para definir MTD1	18
Tabela 2 – Parâmetros utilizados para definir MTD2	20
Tabela 3 – Parâmetros utilizados para definir MTD3	21
Tabela 4 – Parâmetros utilizados para definir MTD4	22

Lista de abreviaturas e siglas

EMG	Eletromiografia
MU	<i>Motor Unit</i>
MUAP	<i>Motor Unit Action Potencial</i>
MUAPT	<i>Motor Unit Action Potencial Trains</i>
MTD#	<i>Método número #</i>
BEP	<i>Beginning Extraction Point</i>
EEP	<i>Ending Extraction Point</i>

Sumário

1	INTRODUÇÃO	14
2	REFERÊNCIA BIBLIOGRÁFICA	16
2.1	Sinais de Eletromiografia	16
2.2	Métodos de Segmentação	17
2.2.1	Método 1 (MTD1) - método iterativo para detecção de centros de segmentos de comprimento constante	18
2.2.2	Método 2 (MTD2) - método não iterativo para detecção de centros de segmentos de comprimento constante	19
2.2.3	Método 3 (MTD3) - método com janela deslizante para detecção de BEP e EEP de segmentos utilizando variação total	21
2.2.4	Método 4 (MTD4) - método com janela deslizante para detecção de BEP e EEP de segmentos utilizando <i>threshold</i>	22
2.3	Redes Neurais Artificiais	23
3	CAPÍTULO TEMPORÁRIO: ORIENTAÇÃO	24
3.1	Questões	24
3.2	Próximos objetivos	24
4	METODOLOGIA EXPERIMENTAL	25
4.1	Aquisição de sinais	25
4.2	Implementação dos Métodos de Segmentação	25
4.2.1	MTD1	25
4.2.2	MTD2	25
4.2.3	MTD3	25
4.2.4	MTD4	25
4.3	Treinamento de Rede Neural Artificial	25
5	RESULTADOS E DISCUSSÕES	26
5.1	MTD1	26
5.1.1	NINAPRO	26
5.1.2	LOPES 2014	26
5.2	MTD2	26
5.2.1	NINAPRO	26
5.2.2	LOPES 2014	26
5.3	MTD3	26

5.3.1	NINAPRO	26
5.3.2	LOPES 2014	26
5.4	MTD4	26
5.4.1	NINAPRO	26
5.4.2	LOPES 2014	26
5.5	Discussões	26
6	CONCLUSÃO	27

1 Introdução

Sinais de EMG apresentam crescentes aplicações no controle de próteses mioelétricas. Por exemplo, (HARGROVE et al, 2013) mostra o controle de prótese de perna de um amputado acima do joelho direito, enquanto (JUN-UK CHU et al, 2007) apresentou bons resultados de reconhecimento de padrões de EMG para desenvolvimento de uma prótese multifuncional de mão. Em áreas não relacionadas à próteses, (CONSTANTINOS S. PATTICHIS et al, 1995) utiliza redes neurais artificiais para realização de diagnósticos clínicos de distúrbios neuromusculares.

As principais estratégias para caracterização de sinais de EMG e potenciais de ação das unidades motoras baseiam-se no uso de um método classificador. Métodos de classificação utilizados incluem - entre inúmeros outros - redes neurais artificiais (HUDGINS et al, 1993), classificador Bayesiano (ENGLEHART and HUDGINS, 2003), modelos de misturas de Gaussianas (HUANG et al, 2004) e lógicas *fuzzy* (CHAN et al, 2000). Tais sistemas de classificação necessitam, como parte do pré-processamento, segmentar os sinais de EMG adquiridos, para então realizar extração de características dos segmentos como amplitude, número de cruzamentos por zero, coeficientes de autoregressão, transformadas de Fourier e, mais recentemente, transformadas Wavelet (JUN-UK CHU et al, 2007).

Este trabalho tem como objetivo implementar em MATLAB quatro diferentes métodos de segmentação automática de sinais de EMG. Os métodos serão aplicados em sinais da base de dados realizada por (LOPES, 2014), que contempla sinais de EMG de superfície provenientes da região do antebraço; e na base de dados NINAPRO (ATZORI et al, 2012), que contém sinais de dez canais de EMG de superfície para 52 diferentes movimentos de mão e punho.

Os primeiros dois métodos (que serão identificados neste estudo pelos mneumônicos MTD1 e MTD2) tratam da detecção de picos do sinal e produzem segmentos de comprimento constante centrados nestes picos. O terceiro (MTD3) e quarto (MTD4) métodos utilizam de janela deslizante para identificação de pontos iniciais e finais dos segmentos, produzindo segmentos de comprimento variável. Para as implementações dos métodos neste estudo, assume-se o conhecimento *a priori* do número de segmentos de interesse contidos no sinal.

O primeiro método (MTD1) é baseado no método de segmentação utilizado em (CHAUVET et al, 2001). Trata-se de método iterativo, identificando os picos do sinal a partir de *threshold* de amplitude, segmentando o sinal em janelas de comprimento constante centradas nos picos. O valor de *threshold* para a primeira iteração corresponde ao máximo absoluto do sinal. A cada nova iteração em que não se atinge um número desejado de

segmentos, o novo *threshold* é calculado como fração do *threshold* da iteração anterior.

O segundo método (MTD2) é baseado no método de segmentação utilizado em (KATSIS et al, 2006). De forma similar ao MTD1, também utiliza *threshold* para detecção de picos do sinal e segmentação com janelas de comprimento constante em torno dos picos. Diferentemente de MTD1, MTD2 não é iterativo, utilizando o valor máximo e o comprimento do sinal para cálculo do valor de *threshold*.

O terceiro método (MTD3) é baseado no método de segmentação utilizado em (GUT and MOSCHYTZ, 2000). Uma janela deslizante percorre o sinal e identifica inícios de segmentos quando a declividade média no interior da janela excede determinado valor de *threshold*. Os finais dos segmentos são identificados quando a variação total do sinal no interior da janela é inferior a um segundo valor de *threshold*.

O quarto método (MTD4) é baseado no método de segmentação utilizado em (PATTICHIS et al, 1995). Os pontos de início do segmento são tais que, em uma janela à esquerda do ponto, o sinal mantém-se abaixo de determinado *threshold*. Os pontos de final de segmento, de forma similar, são tais que, em uma janela à direita do ponto, o sinal mantém-se abaixo do *threshold*.

Utilizando valores de variância e RMS dos sinais segmentados, como no estudo de (SCHONS, 2014) [TODO: DETERMINAR AS CARACTERÍSTICAS A SEREM UTILIZADAS PARA TREINAMENTO DA REDE NEURAL], uma rede neural artificial será treinada para classificar entre possíveis movimentos. O objetivo final deste estudo é avaliar a influência dos métodos de segmentação nas taxas de acerto de classificação.

2 Referência Bibliográfica

2.1 Sinais de Eletromiografia

Sinais de EMG podem ser adquiridos por sensores posicionados na superfície da pele ou por agulhas introduzidas no tecido muscular. Sinais de EMG são compostos por potenciais de ação de fibras musculares organizadas em unidades funcionais chamadas de "unidades motoras" (MU - *Motor Unit*) (DE LUCA et al, 2006). Uma unidade motora é composta por um neurônio motor e as fibras musculares que ele inerva, e é a entidade fundamental que controla a ativação de músculos estriados (BUCHTAL and SCHMALBRUCH, 1980). A soma algébrica dos potenciais de ação de todas as fibras de uma unidade motora é chamada de "potencial de ação da unidade motora", ou em inglês, MUAP (*Motor Unit Action Potential*) (ALMEIDA, 1997). A Figura 1 apresenta a composição de uma MUAP a partir da soma dos potenciais das fibras de uma unidade motora.

Dependendo do método utilizado para aquisição de EMG, é comum a captura da contribuição de mais de uma unidade motora no mesmo canal. A influência de uma unidade motora no sinal adquirido depende principalmente da distância das fibras musculares ao ponto de aquisição (HAMMARBERG and STERNAD, 2002). A Figura 2 apresenta um exemplo com três unidades motoras, cujas MUAPs somadas compõem o sinal adquirido.

Sinais de EMG de longa duração são constituídos por sequências temporais de




Figura 1 – Soma de potenciais de ação das n fibras de uma unidade motora, formando uma MUAP $h(t)$. Adaptado de BASMAJIAN e DE LUCA, 1985




Figura 2 – Os sinais de MUAP correspondentes a três diferentes unidades motoras somam-se para formar o sinal adquirido por um canal de EMG. Adaptado de HAMMARBERG and STERNAD, 2002




Figura 3 – MUAPT's de diferentes MUs somam-se para compor o sinal adquirido por um canal de EMG. Adaptado de KLINE and DE LUCA, 2014

MUAPs, também conhecidas como MUAPT's (*MUAP Trains*). A Figura 3 exemplifica MUAPT's de diferentes MUs que somam-se para formar um sinal de EMG de longa duração.

2.2 Métodos de Segmentação

Esta seção descreve os métodos de segmentação originais que foram utilizados para basear os métodos implementados neste estudo. Nota-se que nomes utilizados para

variáveis e constantes (e.g. ‘ r ’, ‘ T ’, etc.) foram determinados pelo autor deste estudo, não necessariamente sendo estes utilizados nos métodos originais. Para as definições dos métodos 3 e 4 (MTD3 e MTD4) são utilizados os termos BEP (*beginning extraction point*, ponto inicial de um segmento) e EEP (*ending extraction point*, ponto final de um segmento), também utilizados em (PATTICHIS et al, 1995).

2.2.1 Método 1 (MTD1) - método iterativo para detecção de centros de segmentos de comprimento constante

Este é o método iterativo de segmentação utilizado em (CHAUVET et al, 2001). As definições da Tabela 1 serão utilizados para descrever este método.

Tabela 1 – Parâmetros utilizados para definir MTD1

Nome	Descrição
x	Sinal a ser segmentado
L	Comprimento total do sinal a ser segmentado
l	Comprimento desejado para os segmentos
T_k	Valor de <i>threshold</i> para a iteração k
q	Fração de T_{k-1} para determinação de T_k
N_k	Número total de candidatos para centros de segmentos identificados na iteração k
r_k	Razão entre número de candidatos identificados na iteração k e o comprimento total do sinal
r_{target}	Razão mínima esperada para r_k , utilizada para determinar o final do método

Fonte: Do autor.

Inicialmente, determina-se o valor de *threshold* T_0 equivalente ao máximo absoluto do sinal a ser segmentado x (equação (2.1)). O valor T_k é atualizado em cada iteração k como sendo uma fração q de T_{k-1} (equação (2.2)). No trabalho de (CHAUVET et al, 2001), este valor q é de 90%.

$$T_0 = \max(x) \quad (2.1)$$

$$T_k = q \times T_{k-1} \quad (2.2)$$

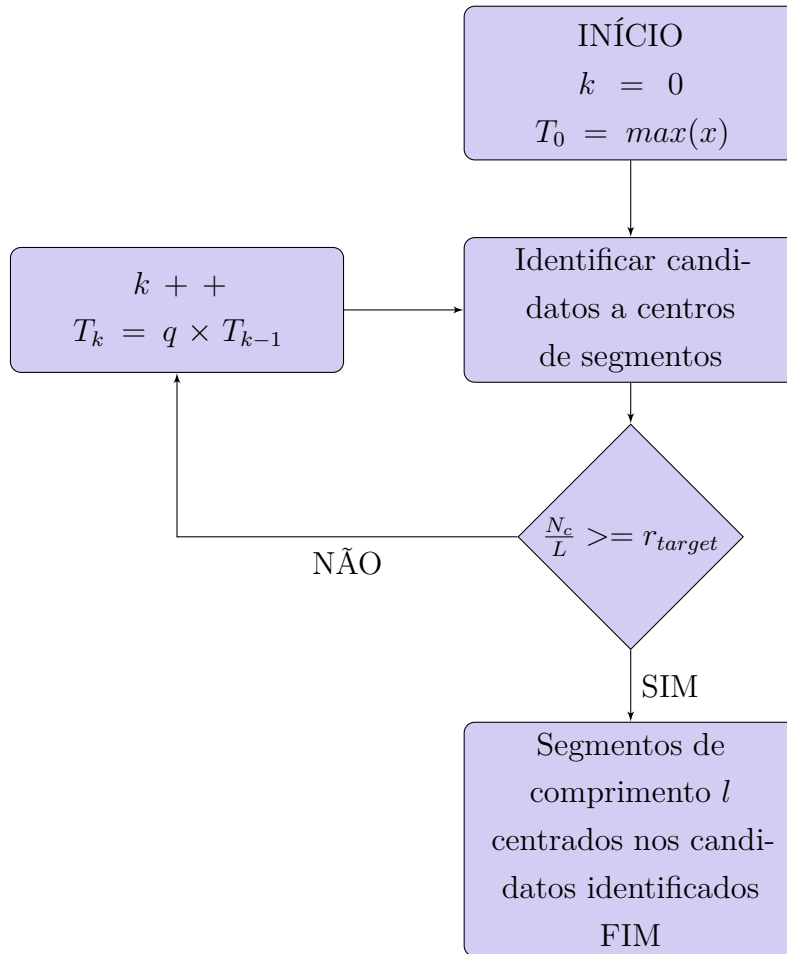
Pontos do sinal acima do valor de T_k são possíveis candidatos para centros de segmentos. Caso exista mais de um possível candidato em uma vizinhança bilateral de l amostras do sinal, apenas o ponto de maior amplitude nesta vizinhança é considerado.

Para determinar o final do método, avalia-se a razão r_k entre a quantidade identificada de candidatos N_k e o comprimento total do sinal L (equação 2.3). Caso r_k seja menor

que um valor predeterminado r_{target} , calcula-se T_{k+1} para realização da próxima iteração (equação 2.2). Caso r_k seja maior ou igual ao valor predeterminado r_{target} , encerra-se o método e os segmentos são tomados como janelas de sinal de comprimento l , centradas nos candidatos identificados na última iteração.

$$r_k = \frac{N_k}{L} \quad (2.3)$$

O seguinte fluxograma resume os passos realizados para segmentação pelo MTD1.



Para ilustrar o MTD1, a Figura 4 apresenta uma implementação em trecho de sinal de EMG retirado da base de dados Ninapro, com fração q de 90% (isto é, $T_k = 0.9 \times T_{k-1}$) e segmentos de comprimento l de 401 amostras.

2.2.2 Método 2 (MTD2) - método não iterativo para detecção de centros de segmentos de comprimento constante

Este é o método de segmentação utilizado em (KATSIS et al, 2006). As definições da Tabela 2 serão utilizados para descrever este método.

Primeiramente, calcula-se o valor de *threshold* T a partir da média, do comprimento L e do valor máximo do sinal a ser segmentado x . No trabalho de (KATSIS et al, 2006), a

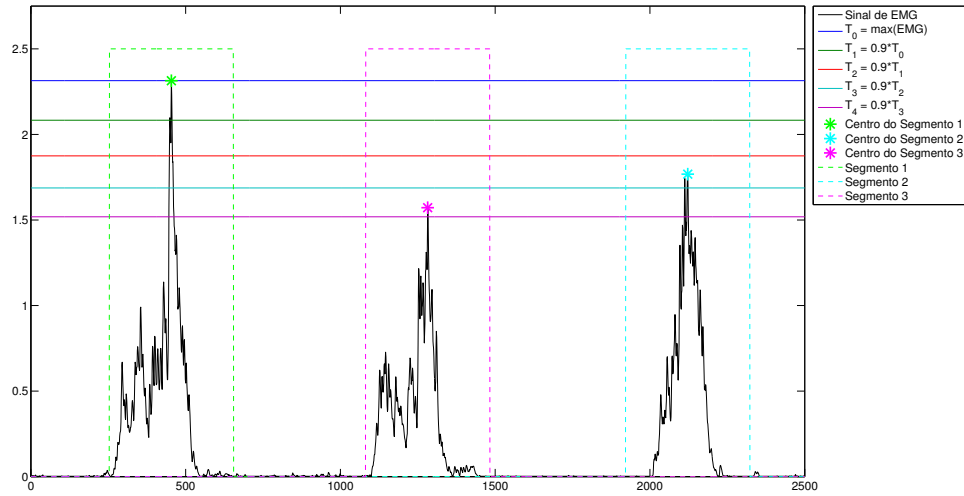


Figura 4 – Ilustração da implementação do MTD1, com $q = 0.9$ e $l = 401$. Do autor.

Tabela 2 – Parâmetros utilizados para definir MTD2

Nome	Descrição
x	Sinal a ser segmentado
L	Comprimento total do sinal a ser segmentado
l	Comprimento desejado para os segmentos
T	Valor de <i>threshold</i>

Fonte: Do autor.

relação utilizada para cálculo de T é dada em (2.4).

$$if \left(\max(x) > \frac{30}{L} \sum_{i=1}^L |x_i| \right); then : T = \frac{5}{L} \sum_{i=1}^L |x_i|; else : T = \frac{\max(x)}{5} \quad (2.4)$$

De forma similar ao MTD1, os pontos do sinal que tiverem valor acima de T são considerados possíveis candidatos para centros de segmentos. Para os possíveis candidatos que estiverem afastados de uma distância inferior a l , apenas o candidato de maior amplitude é considerado. Em (KATSIS et al, 2006) utilizou-se comprimento l de 121 amostras.

A Figura 4 serve para ilustrar o MTD2, apresentando uma implementação em trecho de sinal de EMG retirado da base de dados Ninapro, com segmentos de comprimento l de 401 amostras. O valor de *threshold* T para este exemplo é calculado como $T = \frac{\max(x_i)}{5}$, já que o máximo absoluto do sinal é menor que trinta vezes a média do sinal.

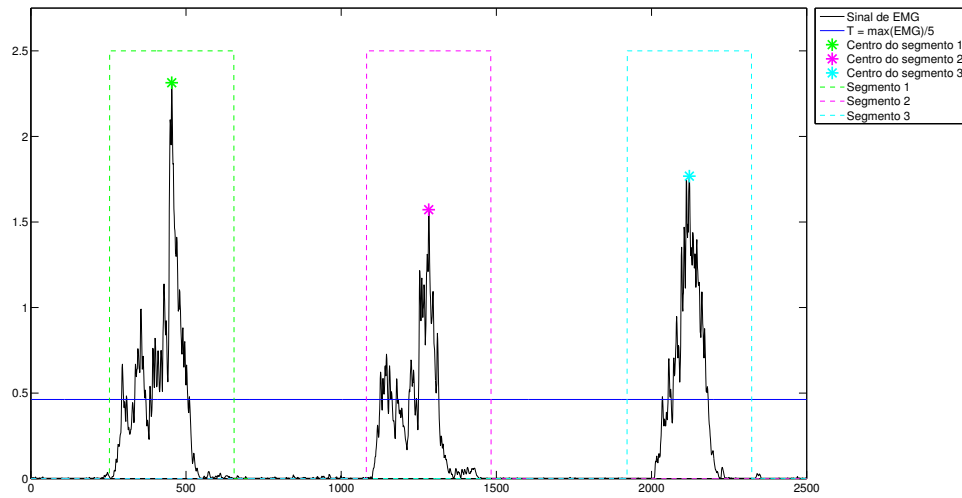


Figura 5 – Ilustração da implementação do MTD2, com $l = 401$. Do autor.

2.2.3 Método 3 (MTD3) - método com janela deslizante para detecção de BEP e EEP de segmentos utilizando variação total

Este é o método de segmentação utilizado em (GUT and MOSCHYTZ, 2000). As definições da Tabela 3 serão utilizados para descrever este método.

Tabela 3 – Parâmetros utilizados para definir MTD3

Nome	Descrição
x	Sinal a ser segmentado
W	Comprimento da janela deslizante utilizada pelo método
w_0	Número da amostra mais a esquerda da janela. Determina a posição instantânea da janela
β	Declividade média do sinal x contido na janela deslizante
B	Valor limite para declividade média que determina ponto inicial de um segmento
γ	Variação total do sinal x contido na janela deslizante
C	Valor limite para variação total que determina ponto final de um segmento

Fonte: Do autor.

Uma janela deslizante de comprimento W percorre o sinal da esquerda para a direita. Caso a declividade média β do trecho de sinal contido pela janela, calculado pela equação (2.5), exceda um limite B , o ponto mais à esquerda da janela w_0 determina a BEP de um segmento.

$$\beta = \frac{1}{W} \sum_{i=w_0+1}^W (x_i - x_{i-1}) \quad (2.5)$$

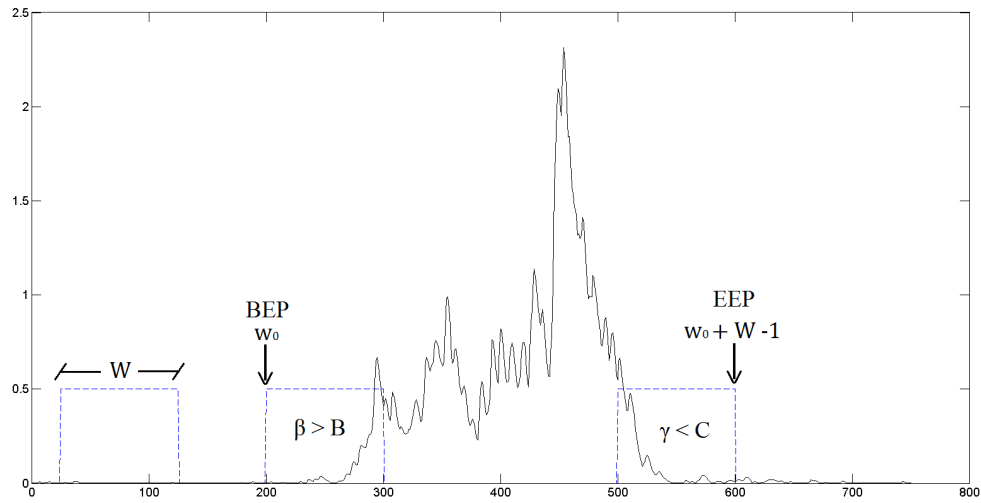


Figura 6 – Ilustração da implementação do MTD3, com $W = 100$. Do autor.

O EEP do correspondente segmento é então obtido como o ponto mais à direita da janela ($w_0 + W - 1$) quando a variação total γ , dado pela equação (2.6), do trecho de sinal contido pela janela for menor que um limite C .

$$\gamma = \sum_{i=w_0+1}^W (x_i - x_{i-1}) \quad (2.6)$$

Nota-se que as equações (2.5) e (2.6) diferem somente pela divisão pelo comprimento da janela W em (2.5). Com valores adequados para os limites B e C , o MTD3 pode ser implementado utilizando apenas uma destas equações. A Figura 6 exemplifica uma janela deslizando que determina BEPs e EEPs de segmentos utilizando o MTD3.

2.2.4 Método 4 (MTD4) - método com janela deslizando para detecção de BEP e EEP de segmentos utilizando *threshold*

Este é o método de segmentação utilizado em (PACHITTIS et al, 1995). As definições da Tabela 4 serão utilizados para descrever este método.

Tabela 4 – Parâmetros utilizados para definir MTD4

Nome	Descrição
x	Sinal a ser segmentado
W	Comprimento da janela deslizando utilizada pelo método
T	Valor de <i>threshold</i>

Fonte: Do autor.

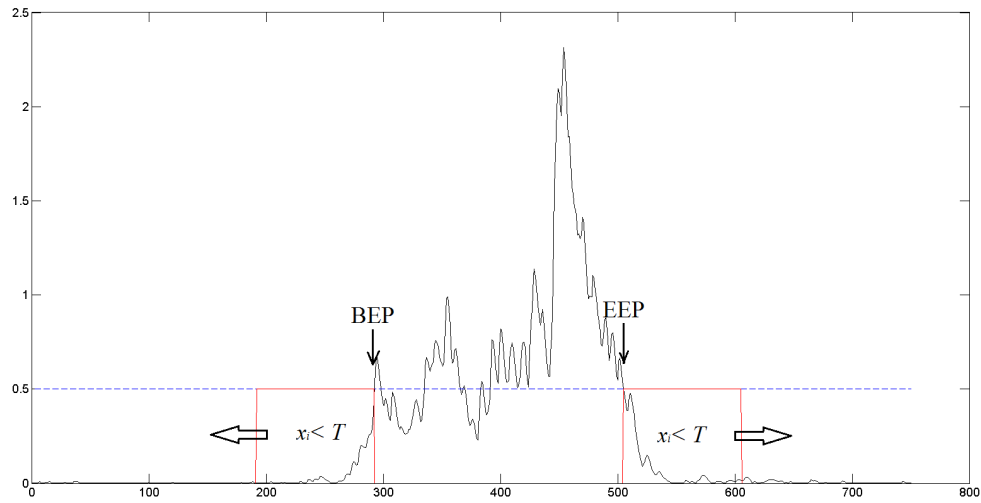


Figura 7 – Ilustração da implementação do MTD4, com $W = 100$ e $T = 0,5$. Do autor.

Primeiramente, a janela deslizante de comprimento W percorre o sinal da direita para a esquerda. Os BEPs dos segmentos são os primeiros pontos (com exceção do final do sinal x) nas quais, com a janela situada à esquerda do ponto, o sinal contido pela janela permanece abaixo do valor de threshold T .

As EEPs são identificadas de forma similar, com a janela percorrendo o sinal da esquerda para a direita. Os EEPs dos segmentos são os primeiros pontos nas quais, com a janela situada à direita do ponto (com exceção do início do sinal x), o sinal contido pela janela permanece abaixo do valor de threshold T .

No trabalho de (PACHITTIS et al, 1995), utilizou-se janelas de comprimento W correspondente a 3 ms de aquisição e *threshold* T de $\pm 40\text{ }\mu\text{V}$ (o sinal de EMG segmentado não era retificado). A Figura 7 exemplifica as determinações de BEPs e EEPs utilizando o MTD4.

2.3 Redes Neurais Artificiais

TODO: REVISÃO SOBRE REDES NEURAIIS

3 CAPÍTULO TEMPORÁRIO: orientação

3.1 Questões

Caro professor Balbinot, no momento necessito sua orientação a respeito dos seguintes itens:

1. Aprovas os métodos de segmentação a serem analisados? Tenho sinal verde para terminar de implementá-los?
2. A respeito dos parâmetros de entrada para rede neural, (FAVIEIRO 2009) utilizou RMS de diferentes canais, e (SCHONS 2014) utilizou RMS e variância. Que características me recomendas utilizar?
3. Qual um número de classes de movimentos interessante para a análise? Já que a base de (LOPES 2014) contempla apenas 9 movimentos, acredito ser uma melhor análise utilizar também somente 9 movimentos da Ninapro, e se possível movimentos parecidos com os coletados em (LOPES 2014). Concordas?

3.2 Próximos objetivos

Darei sequência no trabalho mirando o seguinte:

1. Finalizar implementação dos métodos MTD1 - MTD4 em MATLAB e *tuning* dos parâmetros dos métodos para as duas databases
2. Implementação da rede neural: extração das características, treinamento e validação
3. Realização de análise dos resultados, testes de hipóteses

4 Metodologia Experimental

4.1 Aquisição de sinais

TODO: EXPLICAR COMO FORAM ADQUIRIDOS OS SINAIS DE (LOPES, 2014) E OS SINAIS DA BASE DE DADOS NINAPRO (ATZORI et al, 2012)

4.2 Implementação dos Métodos de Segmentação

4.2.1 MTD1

4.2.2 MTD2

4.2.3 MTD3

4.2.4 MTD4

4.3 Treinamento de Rede Neural Artificial

TODO: DESCRIÇÃO DOS PARÂMETROS UTILIZADOS TODO: DIMENSIONAMENTO E IMPLEMENTAÇÃO DA REDE EM MATLAB

5 Resultados e Discussões

5.1 MTD1

5.1.1 NINAPRO

5.1.2 LOPES 2014

5.2 MTD2

5.2.1 NINAPRO

5.2.2 LOPES 2014

5.3 MTD3

5.3.1 NINAPRO

5.3.2 LOPES 2014

5.4 MTD4

5.4.1 NINAPRO

5.4.2 LOPES 2014

5.5 Discussões

6 Conclusão