

UNIVERSIDADE FEDERAL DO RIO GRANDE DO SUL
ESCOLA DE ENGENHARIA
DEPARTAMENTO DE ENGENHARIA ELÉTRICA
GRADUAÇÃO EM ENGENHARIA ELÉTRICA

VICENTE COSTAMILAN DA CUNHA

**Técnicas de Segmentação Automática de
Sinais de Eletromiografia e Comparação de
Acurácia de Classificação Utilizando Redes
Neurais Artificiais**

Porto Alegre

2015

UNIVERSIDADE FEDERAL DO RIO GRANDE DO SUL
ESCOLA DE ENGENHARIA
DEPARTAMENTO DE ENGENHARIA ELÉTRICA
GRADUAÇÃO EM ENGENHARIA ELÉTRICA

VICENTE COSTAMILAN DA CUNHA

**Técnicas de Segmentação Automática de Sinais de
Eletromiografia e Comparação de Acurácia de
Classificação Utilizando Redes Neurais Artificiais**

Projeto de Diplomação apresentado ao Departamento de Engenharia Elétrica da Escola de Engenharia da Universidade Federal do Rio Grande do Sul, como requisito parcial para Graduação em Engenharia Elétrica

Orientador: Prof. Dr. Eng. Alexandre Balbinot

Porto Alegre

2015

INSERIR A FICHA BIBLIOGRÁFICA

UNIVERSIDADE FEDERAL DO RIO GRANDE DO SUL
ESCOLA DE ENGENHARIA
DEPARTAMENTO DE ENGENHARIA ELÉTRICA
GRADUAÇÃO EM ENGENHARIA ELÉTRICA

VICENTE COSTAMILAN DA CUNHA

Técnicas de Segmentação Automática de Sinais de Eletromiografia e Comparação de Acurácia de Classificação Utilizando Redes Neurais Artificiais

Projeto de Diplomação apresentado ao Departamento de Engenharia Elétrica da Escola de Engenharia da Universidade Federal do Rio Grande do Sul, como requisito parcial para Graduação em Engenharia Elétrica

Trabalho aprovado. Porto Alegre, XX de XXXXXX de 2015:

Prof. Dr. Eng. Alexandre Balbinot
Orientador

Professor
Convidado 1

Professor
Convidado 2

Porto Alegre
2015

INSERIR DEDICATÓRIA

Agradecimentos

INSERIR AGRADECIMENTOS

INSERIR EPÍGRAFE

Resumo

A pesquisa na área de sinais de eletromiografia (EMG) apresenta aplicações relevantes para controle de próteses mecânicas e diagnósticos de distúrbios neuromusculares. A segmentação dos sinais de EMG adquiridos nestas aplicações é parte essencial do pré-processamento, identificando trechos de interesse do sinal conhecidos como segmentos ativos e isolando potenciais de ação de unidades motoras. Neste estudo, dois métodos para segmentação de sinais de EMG foram implementados em MATLAB. O primeiro método é baseado na detecção de picos de sinal, produzindo segmentos de comprimento constante. O segundo método baseia-se na detecção de pontos iniciais e finais dos segmentos ativos, produzindo segmentos de comprimento variável. Os trechos de sinais segmentados para ambos os métodos foram classificados de acordo com os movimentos realizados a partir de uma rede neural artificial treinada com dados do mesmo sujeito. Os resultados para acurácia de classificação mostram que [resultados aqui].

Palavras-chave: Eletromiografia. Segmentação. MATLAB. Base de dados NINAPRO.

Abstract

Research in the field of eletromyographic (EMG) signals are relevant for the control of mechanial prothesis and diagnosis of neuromuscular disorders. EMG signal segmentations play a key part of preprocessing in such applications, identifying active segments and isolating windows of motor unit action potentials. In this study, two segmentation methods were implemented in MATLAB. The first method is based on the detection of signal peaks and produces signal segments of constant length. The second method is based on the detection of beginning end ending points of active segments, producing segments of variable length. The segmented signals were then classified accordingly to the subject's movement by an artificial neural network trained with acquired data from the same subject. Results for classification accuracy show that [resultados aqui].

Keywords: Eletromiography. Segmentation. MATLAB. NINAPRO database.

Lista de ilustrações

Figura 1	– Soma algébrica de potenciais de ação das n fibras de uma unidade motora, formando uma MUAP $h(t)$. Adaptado de BASMAJIAN e DE LUCA, 2006 .	15
Figura 2	– Exemplo de um sinal de MUAP, com algumas de suas características básicas indicadas. Adaptado de BARKHAUS et al, 2013	16
Figura 3	– Os sinais de MUAP correspondentes a três diferentes unidades motoras somam-se para formar o sinal adquirido por um canal de EMG. Adaptado de HAMMARBERG and STERNAD, 2002	16
Figura 4	– MUAPTs de diferentes MUs somam-se para compor o sinal adquirido por um canal de EMG. Adaptado de KLINE and DE LUCA, 2014	17

Lista de tabelas

Lista de abreviaturas e siglas

EMG	Eletromiografia
MU	<i>Motor Unit</i>
MUAP	<i>Motor Unit Action Potencial</i>
MUAPT	<i>Motor Unit Action Potencial Trains</i>
BEP	<i>Beginning Extraction Point</i>
EEP	<i>End Extraction Point</i>

Sumário

1	INTRODUÇÃO	13
1.1	Objetivos	13
2	REFERÊNCIA BIBLIOGRÁFICA	15
2.1	Eletromiografia	15
2.1.1	MUAPs e MUAP Trains	15
2.1.2	Sinais de EMG associados a movimentos	17
2.2	Descrição dos Métodos de Segmentação	17
2.2.1	Método 1: detecção de picos de sinal e janelamento constante em torno dos picos	17
2.2.2	Método 2: detecção de BEPs e EEPs	18
2.3	Redes Neurais Artificiais	18
3	METODOLOGIA EXPERIMENTAL	19
3.1	Aquisição de sinais	19
3.2	Preprocessamento	19
3.3	Implementação dos Métodos de Segmentação	19
3.4	Treinamento da Rede Neural Artificial	19
4	RESULTADOS E DISCUSSÕES	20
5	CONCLUSÃO	21

1 Introdução

Sinais de EMG apresentam crescentes aplicações no controle de próteses mioelétricas. Por exemplo, (HARGROVE et al, 2013) mostra o controle de prótese de perna de um amputado acima do joelho direito, enquanto (JUN-UK CHU et al, 2007) apresentou bons resultados de reconhecimento de padrões de EMG para desenvolvimento de uma prótese multifuncional de mão. Em áreas não relacionadas à próteses, (CONSTANTINOS S. PATTICHIS et al, 1995) utiliza redes neurais artificiais para realização de diagnósticos clínicos de distúrbios neuromusculares. Outras qualidades musculares relacionadas à fadiga e tônus também podem ser obtidas pelos sinais adquiridos.

As principais estratégias para controle das próteses mioelétricas baseiam-se no reconhecimento de padrões dos sinais de EMG com o uso de um método classificador para determinar os movimentos pretendidos pelo usuário da prótese. Os métodos de classificação utilizados incluem - entre inúmeros outros - redes neurais artificiais (HUDGINS et al, 1993), classificador Bayesiano (ENGLEHART and HUDGINS, 2003), modelos de misturas de Gaussianas (HUANG et al, 2004) e lógicas *fuzzy* (CHAN et al, 2000). Tais sistemas de classificação utilizam características de segmentos dos sinais como amplitude, número de cruzamentos por zero, coeficientes de autoregressão, transformadas de Fourier e, mais recentemente, transformadas Wavelet (JUN-UK CHU et al, 2007).

Como parte do pré-processamento do sinal e anterior à extração de parâmetros que são utilizados pelos algoritmos de classificação, é necessário segmentar os sinais de EMG adquiridos de modo a isolar trechos que contêm sinais de EMG associados ao movimento pretendido.

1.1 Objetivos

Este trabalho tem como objetivo implementar em MATLAB duas diferentes técnicas de segmentação automática de sinais de EMG. A primeira técnica é baseada no método utilizado em (KATSIS et al, 2003), que utiliza um valor de *threshold* de amplitude para detecção de picos de sinal e janelas de largura constante centradas em torno dos picos. A segunda técnica é baseada no utilizado por (CONSTANTINOS S. PATTICHIS et al, 1995), que identifica pontos de início (BEP - *beginning extraction point*) e de fim (EEP - *end extraction point*) dos segmentos a partir de janelas deslizantes com *thresholds* de amplitude e comprimento.

Os métodos serão aplicados em sinais da base de dados realizada por (LOPES, 2014), que contempla sinais de EMG de superfície provenientes do conjunto de sete músculos da região do antebraço, e na base de dados NINAPRO (ATZORI et al, 2012), que contém sinais de dez canais de EMG de superfície para 52 diferentes movimentos de mão e punho. Utilizando vetores

de características dos sinais segmentados, uma rede neural artificial será treinada para classificar entre movimentos de interesse, realizando análise da influência do método de segmentação utilizado na taxa de acerto da classificação.

2 Referência Bibliográfica

2.1 Eletromiografia

2.1.1 MUAPs e MUAP Trains

Sinais de EMG podem ser adquiridos por sensores posicionados na superfície da pele ou por agulhas introduzidas no tecido muscular. Sinais de EMG são compostos por potenciais de ação de fibras musculares organizadas em unidades funcionais chamadas de "unidades motoras" (MU - *Motor Unit*) (DE LUCA et al, 2006). Uma unidade motora é composta por um neurônio motor e as fibras musculares que ele inerva, e é a entidade fundamental que controla ativação de músculos estriados (BUCHTAL and SCHMALBRUCH, 1980). A soma algébrica dos potenciais de ação de todas as fibras de uma unidade motora é chamada de "potencial de ação da unidade motora", ou, em inglês, MUAP (*Motor Unit Action Potential*) (ALMEIDA, 1997).

A Figura 1 apresenta a composição de uma MUAP a partir da soma dos potenciais das fibras de uma unidade motora. A Figura 2 exemplifica um sinal de MUAP e algumas de suas características básicas, como fases e amplitude.

Dependendo do método utilizado para aquisição de EMG, é comum a captura da contribuição de mais de uma unidade motora no mesmo canal. A influência de uma unidade motora no sinal adquirido depende principalmente da distância das fibras musculares ao ponto de aquisição (HAMMARBERG and STERNAD, 2002). A Figura 3 apresenta um exemplo com três unidades




Figura 1 – Soma algébrica de potenciais de ação das n fibras de uma unidade motora, formando uma MUAP $h(t)$. Adaptado de BASMAJIAN e DE LUCA, 2006

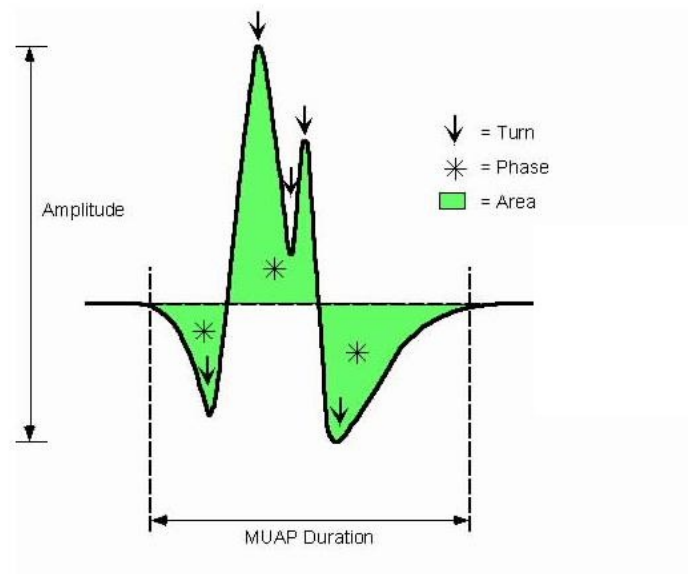


Figura 2 – Exemplo de um sinal de MUAP, com algumas de suas características básicas indicadas. Adaptado de BARKHAUS et al, 2013

motoras, cujas MUAPs somadas compõem o sinal adquirido.

Sinais de EMG de longa duração são constituídos por sequências temporais de MUAPs, também conhecidas como MUAPTs (*MUAP Trains*). A Figura 4 exemplifica MUAPTs de diferentes MUs que somam-se para formar um sinal de EMG de longa duração.




Figura 3 – Os sinais de MUAP correspondentes a três diferentes unidades motoras somam-se para formar o sinal adquirido por um canal de EMG. Adaptado de HAMMARBERG and STERNAD, 2002




Figura 4 – MUAPTs de diferentes MUs somam-se para compor o sinal adquirido por um canal de EMG. Adaptado de KLINE and DE LUCA, 2014

2.1.2 Sinais de EMG associados a movimentos

TODO: DESCREVER MÉTODOS UTILIZADOS PARA ASSOCIAR OS SINAIS A MOVIMENTOS (REGRESSÃO UTILIZANDO SENSORES DE ACELEROMETRIA E GIROSCOPIA, REPETIÇÃO DE MOVIMENTOS EM VÍDEO)

2.2 Descrição dos Métodos de Segmentação

TODO: CRIAR FIGURAS EXPLICATIVAS PARA OS MÉTODOS

Esta seção descreve os princípios dos métodos de segmentação que foram utilizados para basear os métodos desenvolvidos neste estudo.

2.2.1 Método 1: detecção de picos de sinal e janelamento constante em torno dos picos

Este método é inspirado nos métodos utilizados nos trabalhos de (KATSIS et al 2003, 2006 e 2007). Primeiramente, detectam-se os picos de sinal acima de um determinado threshold T de amplitudes. Este threshold T deve ser obtido por relações entre a média, o comprimento e o valor máximo do sinal em questão. Na implementação original em (KATSIS et al, 2006), a relação utilizada para cálculo do threshold T é dada por 2.1.

$$\begin{aligned}
 & \text{if} \left(\max(x_i) > \frac{30}{L} \sum_{i=1}^L |x_i| \right) \\
 & \text{then : } T = \frac{5}{L} \sum_{i=1}^L |x_i|; \text{ else : } T = \frac{\max(x_i)}{5}
 \end{aligned} \tag{2.1}$$

Onde L é o comprimento total do sinal de EMG x . Uma janela de comprimento constante (no caso de KATSIS 2006, utilizou-se 121 amostras) é centrada em cada elemento do sinal x que seja superior ao threshold T , e avalia-se se no interior da janela existe a ocorrência de valor de pico maior em amplitude que o pico original. Caso exista, este pico é o novo centro da janela e repete-se a verificação.

Com este método, os sinais segmentados obtidos serão sempre de comprimento temporal constante e centrados em elementos correspondentes a extremos locais do sinal.

2.2.2 Método 2: detecção de BEPs e EEPs

Este método é inspirado no método de segmentação utilizado em (PATTICHIS et al, 1995). Primeiramente, determina-se uma janela deslizante de comprimento L associada a um threshold de amplitudes T (no trabalho original de PATTICHIS et al, 1995, o comprimento da janela era equivalente a 3 ms e o threshold era de $\pm 40\text{ }\mu\text{V}$). Utilizando esta janela encontram-se os pontos do sinal chamados de BEP e EEP, ou simplesmente início e fim dos segmentos, de modo a atender as seguintes relações:

- BEPs são pontos nos quais os elementos da janela de comprimento L posicionada à esquerda permanecem menores que o threshold T ;
- EEPs são pontos nos quais os elementos da janela de comprimento L posicionada à direita permanecem menores que o threshold T .

Para trechos consecutivos de elementos do sinal que atendem os critérios acima, o BEP escolhido deve ser o elemento mais à direita e o EEP deve ser o elemento mais à esquerda. BEPs e EEPs ocorrem de forma intercalada ao longo do sinal.

Com este método, os sinais segmentados obtidos serão de comprimento variável, dependendo da duração do movimento realizado.

2.3 Redes Neurais Artificiais

TODO: REVISÃO SOBRE REDES NEURAIAS

3 Metodologia Experimental

3.1 Aquisição de sinais

TODO: EXPLICAR COMO FORAM ADQUIRIDOS OS SINAIS DE (LOPES, 2014) E OS SINAIS DA BASE DE DADOS NINAPRO (ATZORI et al, 2012)

3.2 Preprocessamento

TODO: RETIFICAÇÃO E FILTRAGEM DIGITAL DOS SINAIS

3.3 Implementação dos Métodos de Segmentação

TODO: CÓDIGOS MATLAB

3.4 Treinamento da Rede Neural Artificial

TODO: DESCRIÇÃO DOS VETORES DE PARÂMETROS UTILIZADOS TODO: IMPLEMENTAÇÃO DA REDE EM MATLAB

4 Resultados e Discussões

5 Conclusão